PROSPECTAI

Comparaison des modèles d’intelligence artificielle

Justification du choix du modèle de génération pour un système RAG de qualification de prospects B2B

Dossier technique — Novembre 2026

1. Contexte et objectif

ProspectAI est un prototype d’assistance à la recherche, à l’enrichissement et à la qualification de prospects B2B pour Givaudan. Le système s’appuie sur une architecture RAG (Retrieval-Augmented Generation) : il recherche des passages pertinents dans une base documentaire, puis transmet ce contexte à un modèle de langage afin de produire une réponse structurée.

L’objectif de cette étude est de comparer plusieurs modèles de génération compatibles avec une exécution locale, puis de justifier le choix du modèle le plus adapté aux besoins du prototype. La comparaison doit porter sur les mêmes consignes et les mêmes données afin d’être aussi équitable que possible.

2. Environnement technique actuel

Le poste de développement dispose de 16 Go de mémoire vive. Les modèles sont exécutés localement avec Ollama. À la date de la capture fournie, les modèles installés sont :

Modèle installé	Taille affichée	Rôle
qwen3.5:4b	3,3 Go	Modèle de génération : analyse le contexte et formule les réponses.
nomic-embed-text:latest	274 Mo	Modèle d’embedding : transforme les textes en vecteurs pour la recherche sémantique.

Ces deux modèles remplissent des fonctions différentes et complémentaires. Qwen3.5:4b produit les réponses. nomic-embed-text sert à encoder les documents et les requêtes pour retrouver les passages utiles dans ChromaDB. Le modèle d’embedding ne doit donc pas être noté comme un concurrent direct du modèle de génération.

3. Critères de décision

Le choix du modèle de génération repose sur quatre contraintes du projet :

- **Français :** questions et documents en français.
- **Fidélité au contexte (RAG) :** répondre à partir des passages retrouvés dans ChromaDB, sans inventer.
- **Exécution locale :** Ollama sur un poste de 16 Go de RAM, sans API payante.
- **Tâches métier :** comprendre une demande, résumer, repérer des signaux d’opportunité et qualifier un prospect avec la grille 0 à 100.

4. Comparaison des modèles candidats

Le tableau ci-dessous rapproche les candidats de ces contraintes. Les tailles proviennent de sources tierces (bibliothèque Ollama relevée le 30/09/2026, comparatifs de blogs) et sont indicatives : elles servent à décider quoi tester, pas à conclure.

Modèle (tag Ollama)	Taille sur disque (approx.)	Français / multilingue	Compatibilité 16 Go	Décision avant benchmark
qwen3.5:4b	3,4 Go (3,3 Go affichés chez nous) ; environ 4,5 Go avec 32K de contexte	Famille Qwen multilingue ; qualité en français à mesurer	Oui, large marge	**Référence.** Modèle installé, choix initial.
qwen3.5:9b	6,6 Go ; environ 7,7 Go avec 32K de contexte	Idem, avec plus de capacité	Oui, marge correcte (à mesurer)	**À tester.** Gain de qualité probable ; coût en vitesse à mesurer.
gemma4:e4b (Google)	Environ 3,5 Go en Q4 selon un comparatif ; une autre source le dit proche du 9B de Qwen : à vérifier	140+ langues annoncées par Google ; à mesurer en français	Oui	**À tester.** Principal challenger sur le multilinguisme.
phi4-mini (Microsoft)	Environ 2,5 Go	Décrit comme centré sur l'anglais, plus faible hors anglais (comparatif tiers)	Oui	**À tester comme contrôle.** Risque élevé pour le français.
Mistral Small (24B)	Environ 14 Go (Q4), environ 16 Go en usage	Bon candidat rédactionnel en principe	**Non** : sature 16 Go de RAM	**Écarté** pour raison matérielle.
Llama (variantes)	Dépend de la version et de la taille	Variable	Dépend de la taille	**Non retenu** : version non précisée.

Remarque : cette liste constitue un protocole de test proposé, pas un classement établi. Gemma 4 E4B remplace ici Gemma 3:4b prévu initialement, car c'est sa génération successeure ; Gemma 3:4b reste une solution de repli si gemma4:e4b ne fonctionne pas avec la version d'Ollama installée. Aucun modèle ne peut être déclaré vainqueur avant les essais.

5. Pourquoi Qwen3.5:4b a été retenu initialement

- **Compatibilité matérielle.** Sa taille téléchargée (3,3 Go) laisse une marge confortable sur 16 Go de RAM pour le système, ChromaDB, FastAPI et le modèle d'embedding, sous réserve de surveiller la mémoire utilisée par l'ensemble de l'application.
- **Exécution locale.** Ollama permet de lancer le modèle sur le poste de développement, sans dépendre systématiquement d'une API distante payante.
- **Fenêtre de contexte large.** 256K annoncés, largement suffisants pour injecter plusieurs passages récupérés.
- **Génération récente de la famille.** Les versions plus récentes de Qwen sur Ollama (3.6 et 3.8) n'existent qu'en grands formats (27B et plus), inutilisables sur ce poste : Qwen3.5 est la dernière génération disponible en petite taille.
- **Compromis qualité / ressources.** Un modèle plus grand peut produire de meilleures réponses, mais aussi être plus lent et plus coûteux en mémoire. Pour un prototype, un modèle compact est un point de départ raisonnable.

Conclusion provisoire : Qwen3.5:4b a été choisi comme compromis initial pour développer et tester ProspectAI. Ce choix est techniquement défendable au regard des contraintes matérielles et de l'exécution locale, mais il ne prouve pas que Qwen est le meilleur modèle. Seul un benchmark réalisé sur les mêmes données permettra de confirmer ou de remplacer ce choix.

6. Limites de ce choix

1. **Aucune mesure propre au projet.** Les arguments ci-dessus viennent de la documentation et de comparatifs externes, pas de nos tests : c'est une hypothèse raisonnable, pas une preuve.
2. **Le 9B tient probablement sur la machine.** Avec environ 7,7 Go à 32K de contexte, l'argument matériel seul ne suffit pas à l'écarter ; seule la vitesse peut le faire, et elle doit être mesurée.

3. **Qualité en français non démontrée.** Rien ne prouve à ce stade que Qwen3.5:4b soit meilleur que Gemma 4 E4B en français professionnel.
4. **Risque d'invention.** Un petit modèle peut compléter des informations absentes ; pour la qualification de prospects, c'est le défaut le plus coûteux. Il se teste avec des questions dont la réponse n'est pas dans la base.
5. **Mode réflexion.** S'il est actif, il peut allonger fortement les temps de réponse. Il doit être réglé de façon identique pour tous les modèles.

7. Protocole de comparaison (benchmark)

Chaque modèle doit recevoir exactement le même contexte documentaire, la même question et les mêmes paramètres de génération autant que possible (même top-k de passages, même température, même prompt système). Les réponses seront évaluées sur plusieurs cas représentatifs de ProspectAI :

6. Comprendre l'activité d'une entreprise à partir d'informations documentaires.
7. Repérer les catégories de produits, ingrédients ou solutions qui pourraient correspondre aux activités de Givaudan.
8. Identifier des signaux d'opportunité (nouveau produit, recrutement R&D, expansion, innovation), sans inventer de faits.
9. Produire une fiche de qualification claire avec les informations disponibles, les éléments manquants et les sources.
10. Distinguer explicitement les faits documentés des hypothèses commerciales.

Un jeu de 12 à 15 questions identiques sera préparé à l'avance, avec la réponse attendue, dont au moins 3 questions pièges portant sur une information absente de la base (le modèle doit répondre qu'il ne sait pas).

8. Grille de notation proposée

Critère	Pondération	Méthode d'évaluation
Pertinence de l'analyse commerciale	25 points	La réponse identifie-t-elle des besoins et opportunités cohérents avec le contexte ?
Exactitude et absence d'invention	25 points	Les affirmations sont-elles appuyées par les documents ? Les inconnues sont-elles signalées ?
Compréhension et respect de la consigne	20 points	Le modèle répond-il précisément à la question et suit-il le format demandé ?
Qualité des recommandations	15 points	Les recommandations sont-elles concrètes, justifiées et utiles ?
Qualité du français et structure	10 points	La réponse est-elle claire, lisible et correctement organisée ?
Temps de réponse	5 points	Mesurer le temps de génération sur la même machine.

La consommation mémoire (`ollama ps`) et la stabilité seront relevées comme indicateurs techniques complémentaires. Pour limiter les biais, il est recommandé de répéter les tests au moins trois fois, de noter les réponses en aveugle (sans connaître le modèle) par au moins deux personnes, et de conserver les prompts, les réponses et les temps mesurés. Règle d'élimination : un modèle qui invente une information sur plus de la moitié des questions pièges est écarté, quelle que soit sa note globale.

9. Tableau de résultats à compléter

Modèle	Pertinence /25	Exactitude /25	Consigne /20	Recomm. /15	Français /10	Temps /5	Total /100	RAM (Go)
qwen3.5:4b								

Modèle	Pertinence /25	Exactitude /25	Consigne /20	Recomm. /15	Français /10	Temps /5	Total /100	RAM (Go)
qwen3.5:9b								
gemma4:e4b								
phi4-mini								

10. État actuel de l'indexation documentaire

La capture ci-dessous montre l'exécution de ingest.py puis de list.py. Elle confirme que la base documentaire ProspectAI a été découpée en 13 morceaux, encodée avec nomic-embed-text et enregistrée dans la collection ChromaDB nommée story. Cette preuve concerne l'indexation et le modèle d'embedding ; elle ne constitue pas encore un résultat de comparaison des modèles de génération.

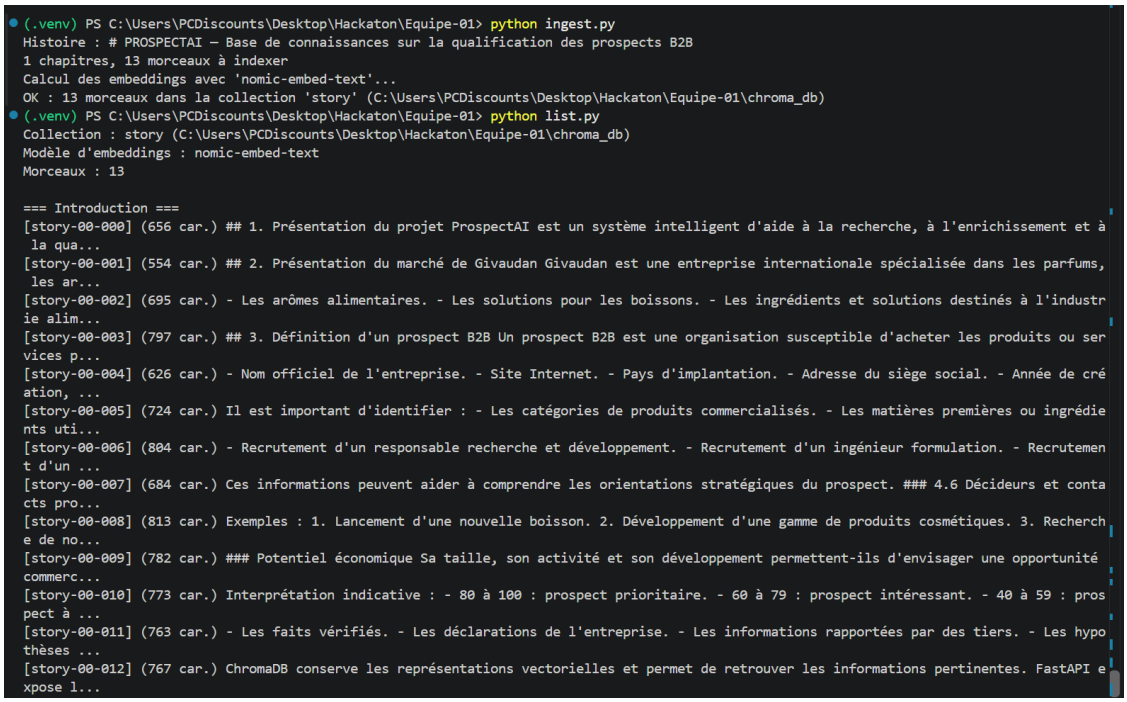


Figure 1 — Sortie du terminal : indexation de 13 morceaux dans ChromaDB avec nomic-embed-text.

Points d'amélioration identifiés : le découpage à taille fixe coupe certaines sections en leur milieu (par exemple un titre séparé de son contenu), la collection porte encore le nom hérité « story », et les fiches des entreprises fictives ne sont pas encore indexées. Corrections prévues : découpage par titres Markdown avec léger chevauchement, renommage de la collection, métadonnées de section et de source, indexation des fiches entreprises avant le benchmark.

11. Conclusion

Qwen3.5:4b est le modèle retenu à ce stade pour ProspectAI parce qu'il permet de développer une solution locale avec une empreinte mémoire modérée et une intégration simple via Ollama. Le système utilise en parallèle nomic-embed-text pour la recherche sémantique dans la base documentaire.

La conclusion définitive dépendra du benchmark : si Qwen3.5:9b, Gemma 4 E4B ou Phi-4-mini fournit des réponses plus exactes, mieux structurées ou plus rapides sur les mêmes cas d'usage, il pourra être préférable de changer de modèle. Le meilleur choix sera celui qui obtient le meilleur équilibre entre qualité des réponses, fidélité aux sources, vitesse et consommation de ressources sur ProspectAI.

Formulation pour la présentation : « Nous avons retenu Qwen3.5:4b comme compromis initial entre qualité attendue, taille et contraintes de notre poste à 16 Go. Nous l'avons ensuite comparé à Qwen3.5:9b, Gemma 4 E4B et Phi-4-mini sur les mêmes questions, avec les résultats suivants. »

Annexe — Commandes utiles pour les essais

```
ollama list
ollama ps
ollama show qwen3.5:4b
ollama run qwen3.5:4b --verbose
ollama run qwen3.5:9b --verbose
ollama run gemma4:e4b --verbose
ollama run phi4-mini --verbose
```

L'option --verbose affiche la vitesse de génération (tokens par seconde). Relever les tailles réelles avec ollama list avant toute présentation.